

Detekcija košarkaške lopte i praćenje uspešnosti šuteva

Jovan Najdovski


Soft computing 2023/2024, Predmetni asistent: Dragan Vidaković, Profesor: dr Jelena Slivka

MOTIVACIJA

- Detekcija objekata ima veoma bitnu ulogu u softverskim rešenjima za praćenje i analizu sportskih utakmica. Klasični pristupi *computer vision*-a i mašinskog učenja često imaju spor odziv u ovom kontekstu. Moderni algoritmi i arhitekture zasnovane na veštačkim neuronskim mrežama, kao što je **YOLO** (You Only Look Once) algoritam, rešavaju ovaj problem bez značajnog gubitka preciznosti.
- Cilj projekta je detekcija i praćenje košarkaške lopte i koša kako bi se olakšalo vođenje statistike.

SKUP PODATAKA


- Za ulazni skup podataka kombinovano je više skupova podataka sa slikama košarkaških lopti i koševa. Skupovi su dobavljeni sa Roboflow platforme gde su i anotirani.
- Ulazni skup podataka ima 17120 slika dimenzija 640x640px i podeljen je na trening (60%), validacioni (20%) i test (20%) skup.
- Prilikom treniranja model dodatno vrši augmentaciju trening podataka rotacijom, skaliranjem, translacijom i menjanjem HSV vrednosti slika.



KORIŠĆENE METODOLOGIJE

Za potrebe ovog istraživanja, korišćen je YOLOv8 model za detekciju objekata. Početni korak obuhvatao je korišćenje pretreniranog modela na manjem skupu drugih klasa objekata. Nakon toga, sproveden je postupak fine-tuning-a, koji se odnosio na dalje uskladjivanje već prethodno obučenog YOLOv8 modela sa specifičnim zahtevima našeg cilja. Ovaj pristup omogućavao je optimizaciju performansi modela u cilju preciznije detekcije i praćenja objekata relevantnih za praćenje košarkaške lopte i koša.


TRENIRANJE MODELA



YOLOv8 model je treniram u 100 epoha sa batch size-om 8 i ulaznim slikama 640x640. Korišćen je early-stopping kako bi se izbegao veći overfitting. Korišćeni su optimizer-i algoritama:

- SGD sa learning rate-om od 0.01
- Adam sa learning rate-om od 0.001

ali se SGD u praksi bolje pokazao.




REZULTATI

Za evaluaciju modela korišćene su metrike: F-value, Precision, Recall, Mean Average Precision (mAP)

	Precision	Recall	F-value	mAP50
BASKETBALL	0.96	0.932	0.945	0.967
RIM	0.978	0.981	0.97	0.989
OBJECT	0.969	0.957	0.957	0.978

Za detekciju postignutih koševa u real-time-u korišćeno je fitovanje krive prethodnih stanja lopte koja je prošla ispod nivoa koša. U slučaju da kriva prolazi blizu centra obruča registrujemo pogodak a u suprotnom promašaj.



ZAKLJUČAK

Gledajući rezultate, postignuta je velika preciznost za ovaj slučaj korišćenja. Međutim u praksi, prilikom praćenja košarkaške lopte može se desiti da objekat neće biti detektovan ukoliko je manjih dimenzija ili je ugao gledanja drugačiji. Baš ovaj slučaj je čest na prenosima utakmica. Model se može poboljšati treniranjem nad većim i raznovrstnijim skupom podataka. Bolju detekciju možemo ostvariti i treniranjem u više epoha kao i korišćenjem ulaznih slika većih dimenzija. Veličinu modela trebamo oprezno posmatrati jer nam ona predstavlja trade-off za odziv koji nam je značajan pri real-time detekciji i praćenju objekata.